

武汉理工大学

Python 数据分析与可视化
大 作 业

题 目	股票相关性分析和价格预测
学 院	经济学院
专 业	经济学类
班 级	2204
姓 名	饶彦哲

2023 年 5 月 22 日

一、项目概述

1.1 项目背景

在股票市场中有许多同类型的股票，他们之间变化趋势会有一定的相关性，可以对同类型股票的历史数据进行相关性分析。可以一定程度上预测其中个别股票的变化，进行实时分析预测，选择投资组合。可以为中低交易量的量化投资做基础准备。

量化投资中一个重要部分便是寻找相关性股票，一种策略可以通过一组相关性股票中价格异常变动获取稳定收益。通过数量化模型建立科学投资体系，以获取稳定收益。

选取了 JPMorgan 和 The Goldman 两家国际最大的银行（投行）的历史股票数据，均为银行，有一定的相关性，并且相对有一般性。

1.2 数据来源

从 kaggle 上下载的 JPMorgan 和 The Goldman 十多年来的股票数据，包含了开盘价，收盘价，当日最高价，当日最低价，调整后收盘价，交易量

1.3 程序功能

1. 对下载的数据可视化 K 线图，可以方便观察股票市场上的变化。
2. 分别对两支股票内的数据进行相关性分析与可视化。
3. 对两支股票收盘价进行相关性分析与可视化。
4. 使用线性回归分析股票价格变化的影响因素。
5. 使用 prophet 进行股票价格趋势预测。

1.4 第三方库

1. Pandas: 是一个用于数据分析的 Python 扩展库，它提供了快速、灵活、清晰的数据结构，可以简单、直观地处理关系型和标记型数据。pandas 库的目标是成为 Python 数据分析实践和实战的必备高级工具，它的长期目标是成为任何语言中最强大、最灵活、开源的数据分析工具。

2. Numpy: 是一个用于科学计算的 Python 扩展库，它提供了高效的多维数组和矩阵运算，以及大量的数学函数库。numpy 库的目标是提供一个简单而强大的工具，可以处理各种数值计算问题，它是基于 C 语言开发的，可以与其他第三方科学计算库很好地集成。

3. Matplotlib: 是一个用于数据可视化的 Python 工具箱，它可以绘制多种多样的数据图形，如折线图、散点图、直方图、饼图等。matplotlib 的目标是提供一个简单而强大的工具，可以用 Python 语言快速地创建静态、动态和交互式的图形。

4. Seaborn: 是一个基于 matplotlib 的 Python 数据可视化库。seaborn 提供了一系列高级的绘图功能，可以用于绘制统计图形，如散点图，小提琴图，热力图，直方图，条形图，密度图等。seaborn 还可以与 pandas 数据结构进行集成，方便对数据进行分析 and 可视化。

5. Prophet: 是一个由 Facebook 开发的用于单变量时间序列预测的开源库。Prophet 实现了一个基于可加模型的时间序列数据预测过程, 拟合了年度、周度、日度的季节性周期变化及节假日效应的非线性趋势。

6. Mplfinance: Mplfinance 是由 matplotlib 开发团队开发的专门用于金融数据可视化分析。使用 Mplfinance 轻松地创建金融可视化图, 支持直接可视化存放在 Pandas DataFrame 中的数据。

7. scikit-learn: 又写作 sklearn, 是一个开源的基于 python 语言的机器学习工具包。它通过 NumPy, SciPy 和 Matplotlib 等 python 数值计算的库实现高效的算法应用, 并且涵盖了几乎所有主流机器学习算法。

二 功能实现

2.1 数据特征初步分析

	Date	Open	High	...	Close	Adj Close	Volume
0	2000-01-03	49.833332	50.250000	...	48.583332	24.406227	12019200
1	2000-01-04	47.083332	47.458332	...	47.250000	23.870712	11723400
2	2000-01-05	46.833332	48.375000	...	46.958332	23.723372	8714550
3	2000-01-06	46.750000	48.625000	...	47.625000	24.060173	8369250
4	2000-01-07	48.416668	49.000000	...	48.500000	24.502220	6571950
...	...	...	...	...	...	...	...
5858	2023-04-17	139.949997	140.059998	...	139.830002	139.830002	16050500
5859	2023-04-18	140.270004	141.779999	...	141.399994	141.399994	13760100
5860	2023-04-19	141.229996	141.500000	...	141.220001	141.220001	9158100
5861	2023-04-20	139.910004	141.429993	...	140.809998	140.809998	10586200
5862	2023-04-21	139.740005	141.110001	...	140.539993	140.539993	11841800

[5863 rows x 7 columns]

两支股票均为从 2000 年至 2023 年 4 月 21 日的数据

2.2 相关性分析

2.2.1 K 线绘制

由于样本量过大，所以取近 3 个月的数据分别绘制 K 线图
第一张为 JPMorgan



第二张为 The Goldman




可以看出无论是交易量还是股票价格，它们的大体趋势相同。
故可以进行相关性分析，通过数据来说明。

2.2.2 相关性分析可视化


先根据历史数据其中调整后的收盘价，计算二者皮尔森相关系数，然后绘制相关性的图表

```
def relation_analysis(df1, df2):  
    # ## 相关性分析  
  
    dfcomp = pd.DataFrame()  
    dfcomp['Close1'] = df1['Adj Close']  
    dfcomp['Close2'] = df2['Adj Close']  
    # ## 用调整后的收盘价来验证两只股票相关性  
  
    retscomp = dfcomp.pct_change()  
    corr = retscomp.corr()  
  
    plt.scatter(retscomp.Close1, retscomp.Close2)  
    plt.xlabel('JPMorgan')  
    plt.ylabel('The goldman')  
    plt.show()  
    ## 绘制皮尔森相关系数散点图  
  
    scatter_matrix(retscomp, diagonal='kde', figsize=(10, 10))  
    plt.show()  
    ## 绘制两只股票收盘价的散点矩阵图  
  
    sns.heatmap(dfcomp.corr(), linewidths=0.1, vmax=1.0, square=True, linecolor='white', annot=True)  
    plt.show()  
    ## 绘制两只股票价格相关性的热力图
```


散点图



散点矩阵图



两支股票价格相关性的热力图




可以看出两支不同股票价格正相关性很强,可印证这两只股票大概率为同类型股票,相似度很高。

之后便仅对一支股票内部影响因素做分析,这里便选取 JPMorgan 的股票进行分析预测。

2.3 股票价格内部影响因素分析

2.3.1 数据构造

考虑到关于收盘价影响因素
绘制相关性热力图



发现关于调整后收盘价格影响数据中，数据影响因素过强，所以构建新的数据

```
def create_data(df):  
    # ## 数据处理  
  
    df['Change'] = (df['Close'] - df['Open']) / df['Open']  
    df['XChange'] = (df['High'] - df['Low']) / df['Low']  
    df = df[['Close', 'Change', 'XChange', 'Volume']]  
    return df
```

2.3.2 数据分析

使用 sklearn 中的线性回归来分析预测


```
def analysis(x, y):
    # ## 使用 sklearn 根据其他数据来预测 Adj Close

    x = skl.preprocessing.scale(x)
    x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.1)
    res = LinearRegression()
    # ## 使用线性回归

    res.fit(x_train, y_train)
    s = res.predict(x_test)
    accuracy = res.score(x_test, y_test)

    print(accuracy)
```

最后得到两组线性回归模拟的得分

```
0.9910519714637317
```

```
0.9901055183483592
```

```
进程已结束,退出代码0
```

得分较高，拟合程度较好

2.4 股票未来价格预测

由于近几年各种其他大环境因素影响（疫情等）

近几年股票价格波动较为异常，于是选择 18 年之前的数据，通过 prophet 进行时序预测。

```
model = Prophet(daily_seasonality=True)
model.fit(df_train)
future = model.make_future_dataframe(periods=365, freq='D')
forecast = model.predict(future)
# ## 模型训练

model.plot(forecast)
plt.show()
model.plot_components(forecast)
# ## 输出时序预测图



df_test = df_test.set_index('ds')
forecast = forecast[['ds', 'yhat']].set_index('ds')
df_test['y'] = np.exp(df_test['y'])
forecast['yhat'] = np.exp(forecast['yhat'])
df_all = forecast.join(df_test).dropna()
df_all.plot()
plt.legend(['true', 'yhat'])
plt.show()
# ## 预测值和真实值进行对比
```

预测图表

浅蓝色：预测上下限

深蓝色：预测范围

黑点：数据散点图



季节相关性等



可以发现，两只股票在季节趋势等方面高度相似，进一步印证了两只股票为同类型股票

与真实值作比较



可以看出，在预测趋势上勉强符合变化趋势，但在实际值上有一定相差。

三 总结

可以通过 python 强大的第三方库 (mplfinance prophet sklearn 等)，用简洁的代码运行出强大的功能，对于量化投资来说至关重要，可以在此基础上通过增加接口，实现股票价格实时监控分析，通过数量化模型建立科学投资体系，以获取相对稳定的收益。